CHARLOTTE FRESENIUS
HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Multivariate Verfahren

Einheit 9: Multivariate (latente) Modellierung (3)

Wintersemester 2025 | Prof. Dr. Stephan Goerigk

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Spezielle Anwendungsbeispiele und Hypothesen mit SEMs

- **Mediation**
  - Direkte und indirekte Effekte: Identifikation von Pfaden, über die eine UV auf eine AV wirkt.
  - Signifikanztest: Prüfung, ob der indirekte Effekt signifikant ist (z. B. Bootstrapping).
  - Praktische Anwendungen: Verständnis von Mechanismen, z. B. wie Interventionen Verhaltensänderungen bewirken.
- **Latente Wachstumskurvenmodelle (vgl. LMM)**
  - Analyse von Veränderungen: Erfassung individueller Entwicklung über die Zeit.
  - Schätzung von Wachstumsparametern: Mittlere Wachstumsrate und Variabilität in der Entwicklung.
  - Vergleich zu LMM: Vorteile durch Berücksichtigung von Messfehlern bei latenten Variablen.
- **Messinvarianzprüfung**
  - Prüfung von Gruppenunterschieden: Überprüfung, ob ein Messmmodell in verschiedenen Gruppen gleich funktioniert.
  - Hierarchische Tests: Vergleich von Modellen mit zunehmenden Restriktionen (konfigural, metrisch, skalär).
  - Praktische Relevanz: Sicherstellung, dass Vergleiche zwischen Gruppen valide sind.

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Mediation vs. Moderation (Pfadanalyse)

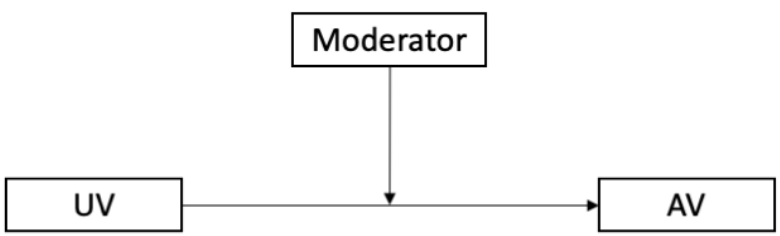
- Moderation und Mediation sind 2 unterschiedliche Konzepte (mit ähnlichen Namen)
- Gemeinsamkeiten:
  - Bei beiden Analysen geht es um ein besseres Verständnis des Zusammenhangs zwischen AV und UV
  - Es geht darum zu prüfen, inwieweit eine dritte Variable in diesen Zusammenhang passt.
- Unterschiede:
  - Moderation: Dritte Variable beeinflusst Stärke des Zusammenhangs zwischen AV und UV
  - Mediation: Dritte Variable vermittelt den Zusammenhang zwischen AV und UV
- Mediator = Bindeglied
- (Teil-)Grund für den Effekt der UV auf AV (Vorsicht Kausalitätsannahmen)

Multivariate (latente) Modellierung

Mediation vs. Moderation (Pfadanalyse)

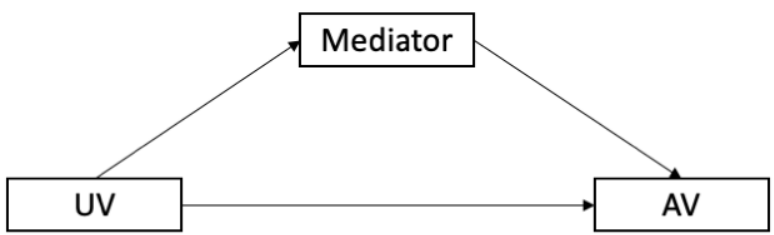
Moderation

Schlafmitteldosis (**UV**) erhöht die Schlafdauer (**AV**); Straßenlärm (**Moderator**) verändert die Stärke des Effekts der Schlafmitteldosis (**UV**) auf die Schlafdauer (**AV**).



Mediation:

Schulnote (**UV**) beeinflusst Selbstwertgefühl (**Mediator**); Selbstwertgefühl (**Mediator**) beeinflusst Lebenszufriedenheit **AV**



→ Da bei Mediation sowohl AV als auch Mediator **endogene** Variablen sind, brauchen wir ein multivariates Modell

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

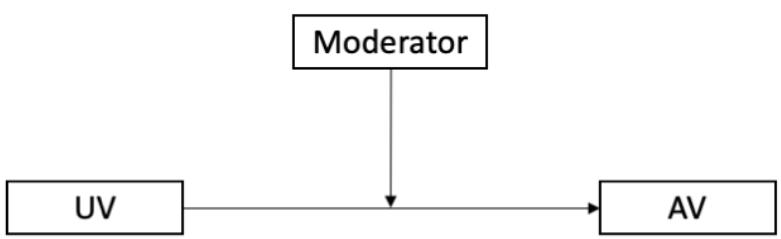
Mediation vs. Moderation (Pfadanalyse)

Moderation

Schlafmitteldosis (**UV**) erhöht die Schlafdauer (**AV**); Straßenlärm (**Moderator**) wirkt zusätzlich auf die **AV**

Statistische Prüfung der Moderationshypothese:

- **Interaktionseffekt**: AV ~ UV x Moderator (wie im Regressionsmodell)
- Frage: Variiert der Effekt von UV auf AV in Abhängigkeit einer weiteren Variable



Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

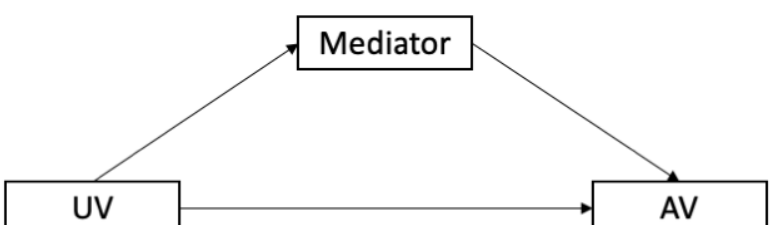
Mediation vs. Moderation (Pfadanalyse)

Mediation:

Schulnote (**UV**) beeinflusst Selbstwertgefühl (**Mediator**); Selbstwertgefühl (**Mediator**) beeinflusst Lebenszufriedenheit **AV**

Statistische Prüfung der Mediationshypothese:

- **Mediator** vermittelt (**mediiert**) den Einfluss der **UV** auf die **AV**
- **Indirekter Effekt: UV** beeinflusst **Mediator**, dies führt zur einem Effekt des **Mediators** auf **AV**
- **Direkter Effekt:** Effekt von **UV** auf **AV** (in Anwesenheit des Mediators)
- **Keine Mediation:** indirekter Effekt nicht signifikant
- **Partielle Mediation:** indirekter Effekt signifikant und direkter Effekt auch signifikant
- **Vollständige Mediation:** indirekter Effekt signifikant und direkter Effekt nicht mehr signifikant.



Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Moderation (Pfadanalyse)

Moderation - Beispiel: Faktoren für Erfolg einer Therapie

- Datensatz für $N = 52$ Therapeut:innen
- **Forschungsfrage:** Was kann als Prädiktor für Therapieerfolg gelten? Gibt es Interaktionen?
- Es wurden folgende Variablen gemessen:
- Therapieerfolg (AV; 0-100 Punkte)
- Therapieerfahrung der Therapeut:in (UV; niedrig, hoch)
- Bereitschaft Patient:in zu konfrontieren (UV 0-100 Punkte)
- Die ersten 15 Fälle sind in der Tabelle rechts dargestellt.

Therapieerfolg	Erfahrung	Konfrontativ	Erfahrung_dummy
89	hoch	61	1
54	niedrig	48	0
62	hoch	23	1
36	niedrig	69	0
54	niedrig	53	0
77	hoch	39	1
41	niedrig	62	0
46	niedrig	62	0
54	niedrig	61	0
71	hoch	58	1
50	niedrig	56	0
75	hoch	44	1
51	niedrig	39	0
66	niedrig	38	0
73	hoch	32	1

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

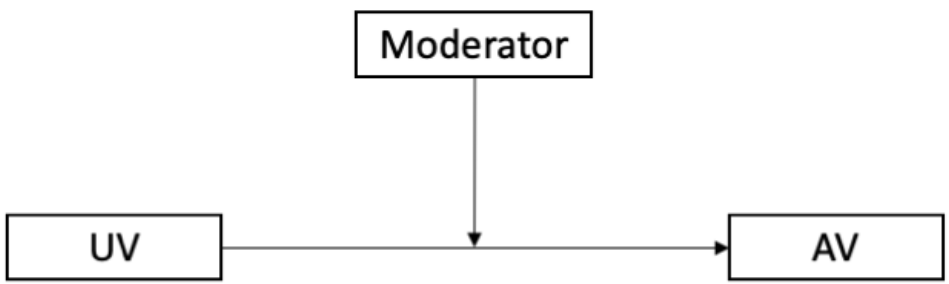
Moderation (Pfadanalyse)

Moderation - Beispiel: Faktoren für Erfolg einer Therapie

Mögliche Forschungsfragen im Modell:

1. Verändert sich der Therapieerfolg von unerfahrenen Therapeut:innen mit zunehmender Konfrontationsbereitschaft?
2. Verändert sich der Therapieerfolg von erfahrenen Therapeut:innen mit zunehmender Konfrontationsbereitschaft?
3. Ist der Effekt der Konfrontationsbereitschaft auf den Therapieerfolg in den Gruppen signifikant unterschiedlich?

→ Die dritte Frage stellt eine Moderationshypothese dar (rechts dargestellt)



- AV: Therapieerfolg
- UV: Konfrontationsbereitschaft
- Moderator: Erfahrung

Moderation: *Beeinflusst die Erfahrung den Effekt der Konfrontationsbereitschaft auf den Therapieerfolg?* (Beispielserklärung: Erfahrenere Therapeut:innen können besser konfrontieren.)

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Moderation (Pfadanalyse)

Moderation - Beispiel: Faktoren für Erfolg einer Therapie

```
model = lm(Therapieerfolg ~ Erfahrung * Konfrontativ, data = df)
summary(model)
```

```
##
## Call:
## lm(formula = Therapieerfolg ~ Erfahrung * Konfrontativ, data = df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -13.0279  -4.6580  -0.1674   4.3870  19.0061
##
## Coefficients:
##                             Estimate Std. Error t value Pr(>|t|)
## (Intercept)                  73.1303     5.3550  13.657  < 2e-16 ***
## Erfahrunghoch               -15.2556     6.2921  -2.425 0.019140 *
## Konfrontativ                 -0.4427     0.1069  -4.143 0.000138 ***
## Erfahrunghoch:Konfrontativ    0.8216     0.1263   6.507  4.2e-08 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 7.023 on 48 degrees of freedom
## Multiple R-squared:  0.7981,    Adjusted R-squared:  0.7855
## F-statistic: 63.24 on 3 and 48 DF,  p-value: < 2.2e-16
```

Interpretation der Koeffizienten:

- Therapeut:innen mit niedriger Erfahrung (Erfahrung=0) haben bei einer Konfrontationsbereitschaft = 0 einen geschätzten Therapieerfolg von 73.13 Punkten
- Therapeut:innen mit hoher Erfahrung (Erfahrung=1) haben bei einer Konfrontationsbereitschaft = 0 einen geschätzten Therapieerfolg von -15.26 Punkten weniger, als die Referenzgruppe

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Moderation (Pfadanalyse)

Moderation - Beispiel: Faktoren für Erfolg einer Therapie

```
model = lm(Therapieerfolg ~ Erfahrung * Konfrontativ, data = df)
summary(model)
```

```
##
## Call:
## lm(formula = Therapieerfolg ~ Erfahrung * Konfrontativ, data = df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -13.0279  -4.6580  -0.1674   4.3870  19.0061
##
## Coefficients:
##                             Estimate Std. Error t value Pr(>|t|)
## (Intercept)                  73.1303     5.3550  13.657  < 2e-16 ***
## Erfahrunghoch               -15.2556     6.2921  -2.425 0.019140 *
## Konfrontativ                 -0.4427     0.1069  -4.143 0.000138 ***
## Erfahrunghoch:Konfrontativ    0.8216     0.1263   6.507  4.2e-08 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 7.023 on 48 degrees of freedom
## Multiple R-squared:  0.7981,    Adjusted R-squared:  0.7855
## F-statistic: 63.24 on 3 and 48 DF,  p-value: < 2.2e-16
```

Interpretation der Koeffizienten:

- Mit 1 Einheit zusätzlicher Konfrontationsbereitschaft nimmt der Therapieerfolg von Therapeut:innen mit niedriger Erfahrung um -0.44 Punkte ab $(t_{48} = -4.14, p < .001)$.
- Mit 1 Einheit zusätzlicher Konfrontationsbereitschaft nimmt der Therapieerfolg von Therapeut:innen mit hoher Erfahrung um 0.82 Punkte mehr zu, als bei der Referenzgruppe $(t_{48} = 6.51, p < .001)$.
- Insgesamt nimmt der Therapieerfolg bei von Therapeut:innen mit hoher Erfahrung mit 1 Einheit zusätzlicher Konfrontationsbereitschaft also um -0.44 + 0.82 = 0.38 Punkte zu

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Moderation (Pfadanalyse)

Moderation - Beispiel: Faktoren für Erfolg einer Therapie

Moderation in `lavaan`:

- Interaktion muss aktiv in Daten angelegt werden
- Interaktion = Produkt der Prädiktoren

```
library(lavaan)

df$Interaktion = df$Erfahrung_dummy * df$Konfrontativ

model = '
Therapieerfolg ~ Erfahrung + Konfrontativ + Interaktion
'
```

- Dann wird das formulierte Modell auf Daten angepasst

```
fit = sem(model, data = df)
```

Therapieerfolg	Erfahrung	Konfrontativ	Erfahrung_dummy	Interaktion
89	hoch	61	1	61
54	niedrig	48	0	0
62	hoch	23	1	23
36	niedrig	69	0	0
54	niedrig	53	0	0
77	hoch	39	1	39
41	niedrig	62	0	0
46	niedrig	62	0	0
54	niedrig	61	0	0
71	hoch	58	1	58
50	niedrig	56	0	0
75	hoch	44	1	44
51	niedrig	39	0	0
66	niedrig	38	0	0
73	hoch	32	1	32

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Moderation (Pfadanalyse)

Moderation - Beispiel: Faktoren für Erfolg einer Therapie

```
model = lm(Therapieerfolg ~ Erfahrung * Konfrontativ, data = df)
summary(model)
```

```
##
## Call:
## lm(formula = Therapieerfolg ~ Erfahrung * Konfrontativ, data = df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -13.0279  -4.6580  -0.1674   4.3870  19.0061
##
## Coefficients:
##                             Estimate Std. Error t value Pr(>|t|)
## (Intercept)                  73.1303     5.3550  13.657  < 2e-16 ***
## Erfahrunghoch               -15.2556     6.2921  -2.425 0.019140 *
## Konfrontativ                 -0.4427     0.1069  -4.143 0.000138 ***
## Erfahrunghoch:Konfrontativ    0.8216     0.1263   6.507  4.2e-08 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 7.023 on 48 degrees of freedom
## Multiple R-squared:  0.7981,    Adjusted R-squared:  0.7855
## F-statistic: 63.24 on 3 and 48 DF,  p-value: < 2.2e-16
```

```
# In lavaan
summary(fit, fit.measures = TRUE) # Modellfit
```

```
User Model versus Baseline Model:

  Comparative Fit Index (CFI)                    1.000
  Tucker-Lewis Index (TLI)                       1.000

Loglikelihood and Information Criteria:

  Loglikelihood user model (H0)               -173.061
  Loglikelihood unrestricted model (H1)       -173.061

  Akaike (AIC)                                 354.123
  Bayesian (BIC)                               361.928
  Sample-size adjusted Bayesian (SABIC)        349.366

Root Mean Square Error of Approximation:

  RMSEA                                          0.000
  90 Percent confidence interval - lower         0.000
  90 Percent confidence interval - upper         0.000
  P-value H_0: RMSEA <= 0.050                       NA
  P-value H_0: RMSEA >= 0.080                       NA
```

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Moderation (Pfadanalyse)

Moderation - Beispiel: Faktoren für Erfolg einer Therapie

```
model = lm(Therapieerfolg ~ Erfahrung * Konfrontativ, data = df)
summary(model)
```

```
##
## Call:
## lm(formula = Therapieerfolg ~ Erfahrung * Konfrontativ, data = df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -13.0279  -4.6580  -0.1674   4.3870  19.0061
##
## Coefficients:
##                             Estimate Std. Error t value Pr(>|t|)
## (Intercept)                  73.1303     5.3550  13.657  < 2e-16 ***
## Erfahrunghoch               -15.2556     6.2921  -2.425 0.019140 *
## Konfrontativ                 -0.4427     0.1069  -4.143 0.000138 ***
## Erfahrunghoch:Konfrontativ    0.8216     0.1263   6.507  4.2e-08 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 7.023 on 48 degrees of freedom
## Multiple R-squared:  0.7981,    Adjusted R-squared:  0.7855
## F-statistic: 63.24 on 3 and 48 DF,  p-value: < 2.2e-16
```

```
# In lavaan
summary(fit, fit.measures = TRUE) # Parameterübersicht
```

```
Parameter Estimates:

  Standard errors                             Standard
  Information                                 Expected
  Information saturated (h1) model          Structured

Regressions:
                   Estimate  Std.Err  z-value  P(>|z|)
  Therapieerfolg ~
    Erfahrung       -15.256    6.045   -2.524    0.012
    Konfrontativ     -0.443    0.103   -4.312    0.000
    Interaktion       0.822    0.121    6.772    0.000

Variances:
                   Estimate  Std.Err  z-value  P(>|z|)
   .Therapieerfolg   45.528    8.929    5.099    0.000
```

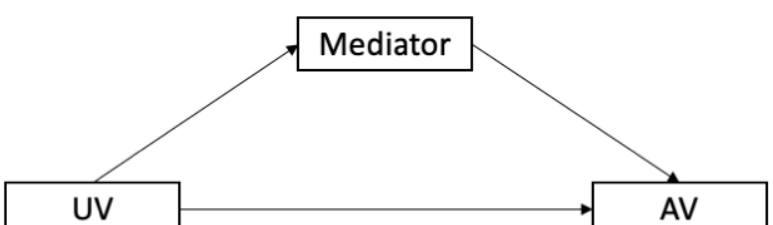
Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Mediation (Pfadanalyse)

Beispiel Mediation: Flüssigkeitszufuhr

- UV (X) = Raumtemperatur
- Mediator (M) = Durst (Skala von 1-10)
- AV (Y) = Getrunkene Gläser
- $N = 50$ (rechts nur 15 Zeilen dargestellt)



Raumtemperatur	Durst	Getraenke
18	4	2
19	4	3
25	5	3
20	5	3
20	4	2
25	7	5
21	3	1
16	4	1
18	4	2
19	4	4
24	5	3
21	4	3
21	4	1
20	3	2
18	3	2

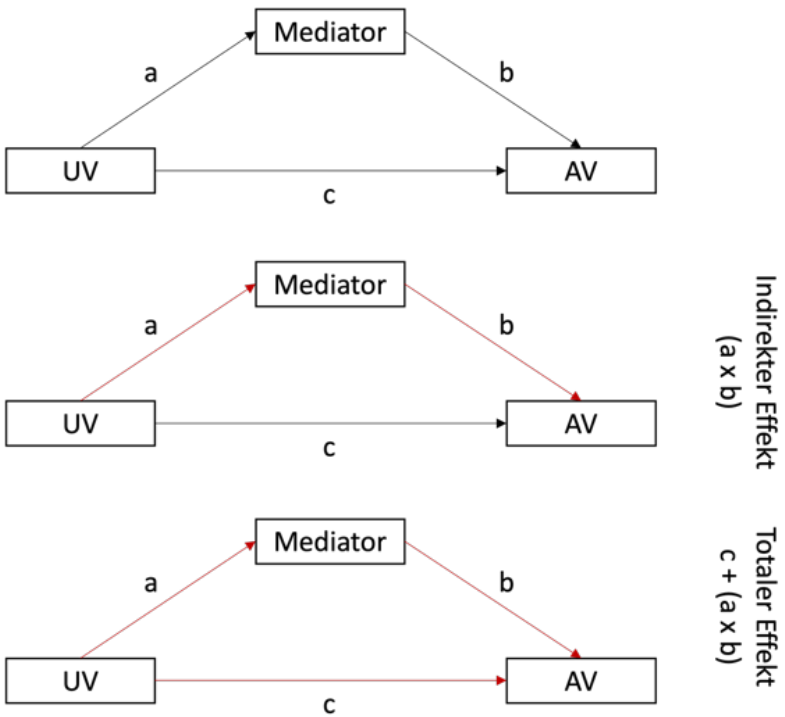
Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Mediation (Pfadanalyse)

Mediation in `lavaan`

```
model <- ' # Direkter Effekt
             Y ~ c * X
           # Mediator
             M ~ a * X
             Y ~ b * M
           # Indirekter Effect (a*b)
             ab := a*b
           # Totaler Effect
             total := c + (a*b)
         '
fit <- sem(model, data = df)
```



Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Mediation (Pfadanalyse)

Beispiel Mediation: Flüssigkeitszufuhr

```
model <- ' # Direkter Effekt
             Getraenke ~ c * Raumtemperatur
           # Mediator
             Durst ~ a * Raumtemperatur
             Getraenke ~ b * Durst
           # Indirekter Effect (a*b)
             ab := a*b
           # Totaler Effect
             total := c + (a*b)
         '
set.seed(123) # Zufällifgkeit reproduzieren

fit <- sem(model,
           data = df,
           se = "bootstrap",
           bootstrap = 1000)
```

Raumtemperatur	Durst	Getraenke
18	4	2
19	4	3
25	5	3
20	5	3
20	4	2
25	7	5
21	3	1
16	4	1
18	4	2
19	4	4
24	5	3
21	4	3
21	4	1
20	3	2
18	3	2

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Mediation (Pfadanalyse)

```
summary(fit, fit.measures = TRUE)
```

- Keine latenten Variablen im Modell (Pfadanalyse)
- Fit Indizes geben optimalen Fit an
- Achtung: Bei Mediation mit latenten Variablen muss vor der Interpretation der Modellfit geprüft werden

```
User Model versus Baseline Model:

  Comparative Fit Index (CFI)                    1.000
  Tucker-Lewis Index (TLI)                       1.000

Loglikelihood and Information Criteria:

  Loglikelihood user model (H0)               -131.480
  Loglikelihood unrestricted model (H1)       -131.480

  Akaike (AIC)                                 272.960
  Bayesian (BIC)                               282.520
  Sample-size adjusted Bayesian (SABIC)        266.826

Root Mean Square Error of Approximation:

  RMSEA                                          0.000
  90 Percent confidence interval - lower         0.000
  90 Percent confidence interval - upper         0.000
  P-value H_0: RMSEA <= 0.050                       NA
  P-value H_0: RMSEA >= 0.080                       NA

Standardized Root Mean Square Residual:

  SRMR                                           0.000
```

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Mediation (Pfadanalyse)

- a: Raumtemperatur sagt Durst signifikant vorher $(\beta = 0.20, p < .001)$
- b: Durst sagt Getränkezahl signifikant vorher $(\beta = 0.54, p = .001)$.
- Indirekter Pfad $a \cdot b$: Der Effekt von Raumtemperatur auf Getränkezahl wird signifikant durch Durst mediiert $(\beta = 0.11, p = .008)$.
- Direkter Pfad c: Wenn $a \cdot b$ berücksichtigt wird, ist Pfad von Raumtemperatur auf Getränkezahl nicht signifikant $(\beta = 0.05, p = .407)$
- Da $a \cdot b$ signifikant und c nicht signifikant $\rightarrow$ Totale Mediation
- Falls $a \cdot b$ signifikant und c auch signifikant wäre $\rightarrow$ Partielle Mediation

```
summary(fit, fit.measures = TRUE)
```

```
Parameter Estimates:

  Standard errors                           Bootstrap
  Number of requested bootstrap draws            1000
  Number of successful bootstrap draws           1000

Regressions:
                   Estimate  Std.Err  z-value  P(>|z|)
  Getränke ~
    Raumtmprtr (c)    0.048    0.058    0.830    0.407
  Durst ~
    Raumtmprtr (a)    0.197    0.038    5.208    0.000
  Getränke ~
    Durst      (b)    0.543    0.162    3.357    0.001

Variances:
                   Estimate  Std.Err  z-value  P(>|z|)
   .Getränke          0.923    0.166    5.576    0.000
   .Durst             0.714    0.145    4.936    0.000

Defined Parameters:
                   Estimate  Std.Err  z-value  P(>|z|)
    ab                0.107    0.040    2.669    0.008
    total             0.155    0.052    3.007    0.003
```

Mediation (Pfadanalyse)

Mediation und Bootstrapping

- In `sem(model, data = df, se = "bootstrap", bootstrap = 1000)` wird ein Bootstrap mit 1000 Wiederholungen angefordert.
- Gründe für die Verwendung von Bootstrappig:
- Indirekter Effekt $(a \cdot b)$ hat häufig eine schiefe oder asymmetrische Verteilung. Bootstrapping umgeht die Annahme der Normalverteilung und liefert zuverlässigere Ergebnisse.
- Klassische Tests wie der Sobel-Test setzen Normalverteilung voraus und sind daher oft ungenau. Bootstrapping ermöglicht eine direkte Signifikanzprüfung des indirekten Effekts.
- Bootstrapping erstellt empirische Konfidenzintervalle durch Resampling, die die tatsächliche Verteilung der Daten besser abbilden.
- Bootstrapping liefert auch bei geringer Datenmenge robuste Schätzungen für indirekte Effekte.

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Mediation (Pfadanalyse)

Darstellung in Tabellenform

```
library(flextable)
flextable(parameterestimates(fit, boot.ci.type = "bca.simple") )
```

lhs	op	rhs	label	est	se	z	pvalue	ci.lower	ci.upper
Getraenke	~	Raumtemperatur	c	0.04825453	0.05816385	0.8296309	0.40674750713973	-0.06549829	0.1717305
Durst	~	Raumtemperatur	a	0.19715395	0.03785761	5.2077761	0.00000019111732	0.12785061	0.2834503
Getraenke	~	Durst	b	0.54264600	0.16162837	3.3573684	0.00078688178027	0.15546291	0.8184489
Getraenke	~~	Getraenke		0.92348346	0.16560371	5.5764661	0.00000002454537	0.65833290	1.3358763
Durst	~~	Durst		0.71393739	0.14465260	4.9355309	0.00000079933037	0.47654349	1.0399607
Raumtemperatur	~~	Raumtemperatur		7.73000000	0.00000000			7.73000000	7.7300000
ab	:=	a*b	ab	0.10698480	0.04009173	2.6685004	0.00761906852804	0.03710583	0.1907947
total	:=	c+(a*b)	total	0.15523933	0.05162646	3.0069719	0.00263864182693	0.05179140	0.2599020

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Mediation (Pfadanalyse)

Graphische Darstellung

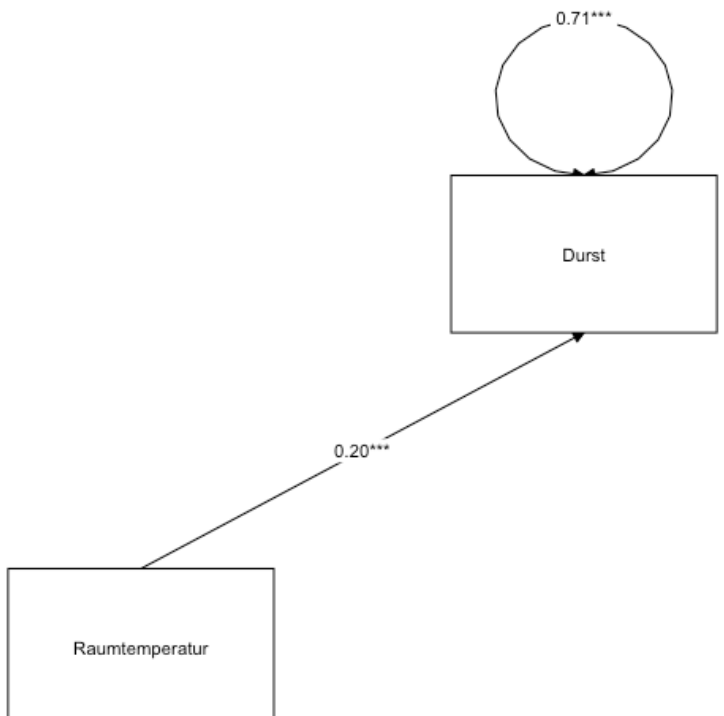
```
library(tidySEM)

# Anordnung im Plot definieren

layout = get_layout("", "Durst", "",
                    "Raumtemperatur", "", "Getränke",
                    rows = 2)

# Graph erstellen

graph_sem(model = fit,
          layout = layout)
```



Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Latente Wachstumskurvenmodelle

- Mit latenten Wachstumskurvenmodellen lassen sich Messwiederholungen modellieren
- Ähnlich wie beim LMM gibt es einen Intercept und einen Slope
  - Intercept = Durchschnitt zu Zeitpunkt 0
  - Slope = Durchschnittliche Veränderung, wenn Zeit (t) um 1 Einheit zunimmt
- In latenten Wachstumskurvenmodellen haben Intercept und Slope eine Varianz (sie dürfen also variieren)
  - $\rightarrow$ entspricht LMM mit random Intercepts und random Slopes
- Vorteil der latenten Wachstumskurvenmodelle gegenüber LMM
  - Veränderung mehrerer AVs gleichzeitig modellierbar (multivariat)
  - Man kann Veränderung einer Variable mit Veränderung anderer Variable vorhersagen

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Latente Wachstumskurvenmodelle

Beispiel: Latente Wachstumskurvenmodelle: Therapieansprechen

- Depressionsstudie mit $N = 80$ Patient:innen
- Baseline (t_0) und 5 Verlaufsmessungen (t_{1-5})
- Patienten erhalten eine Psychotherapie
- Hypothese: Abnahme der Symptomatik im Verlauf (negativer Slope)

subject	t0	t1	t2	t3	t4	t5
21a	43	39	30	32	32	21
22a	35	35	24	17	21	24
23a	40	37	31	24	31	21
24a	36	36	32	25	33	26
25a	35	32	24	20	27	27
26a	39	34	32	27	34	21
27a	32	26	24	22	13	8
28a	40	41	26	30	24	22
29a	39	34	32	17	22	11
30a	38	42	27	19	12	19
31a	39	33	33	29	22	24
32a	36	36	28	27	27	17
33a	37	41	24	33	34	30
34a	34	29	30	23	19	24
35a	36	35	29	19	22	19

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Latente Wachstumskurvenmodelle

Beispiel: Latente Wachstumskurvenmodelle: Therapieansprechen

Vergleich LMM:

```r
# Datensatz ist im wide Format (s.h. vorherige Folie)
# In das long Format umstrukturieren

long = pivot_longer(df,
                    cols = c("t0", "t1", "t2", "t3", "t4", "t5"),
                    names_to = "Time",
                    values_to = "Score")

# Zeitvariable numerisch machen, um kontinuierlichen Slope berechnen zu können

long$Time_num = as.numeric(factor(long$Time)) - 1

library(lme4)
library(lmerTest)

lmm_model = lmer(Score ~ Time_num + (Time_num|subject), data = long)
```

subject	Time	Score	Time_num
21a	t0	43	0
21a	t1	39	1
21a	t2	30	2
21a	t3	32	3
21a	t4	32	4
21a	t5	21	5
22a	t0	35	0
22a	t1	35	1
22a	t2	24	2
22a	t3	17	3
22a	t4	21	4
22a	t5	24	5
23a	t0	40	0
23a	t1	37	1
23a	t2	31	2

Multivariate (latente) Modellierung

Latente Wachstumskurvenmodelle

Beispiel: Latente Wachstumskurvenmodelle: Therapieansprechen

Vergleich LMM:

- Fixed und Randomeffekte enthalten
- Zur Baseline haben Pat. einen Symptomwert von 37.90 (Intercept)
- Pro Messung nehmen Symptome durchschnittlich um -2.41 Punkte ab (Slope)

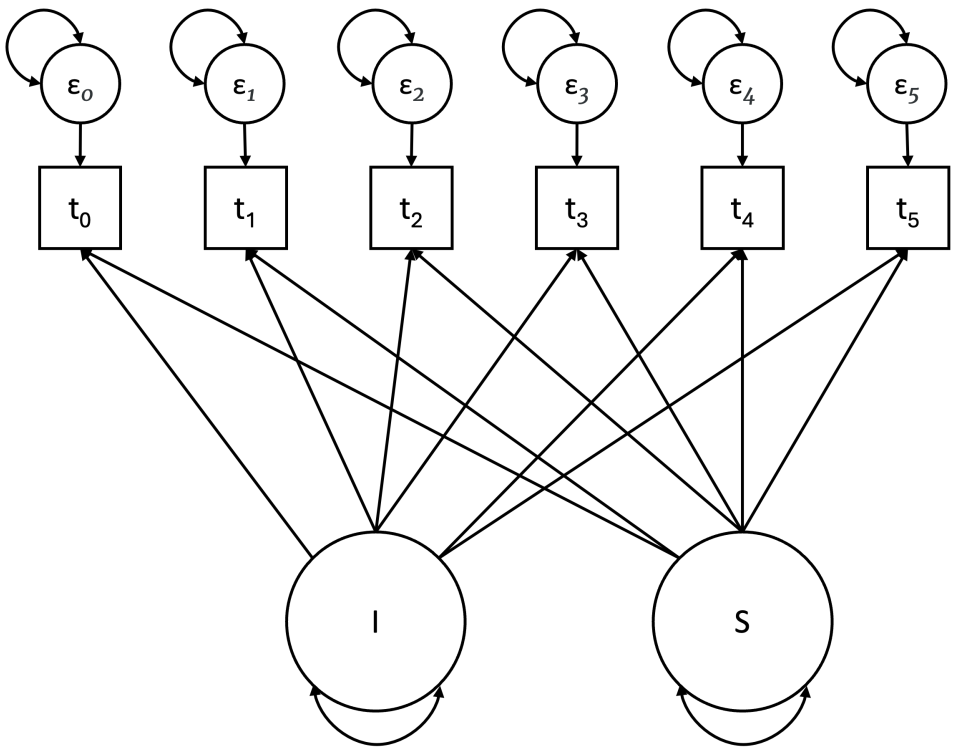
```
summary(lmm_model)
```

```
## Linear mixed model fit by REML. t-tests use Satterthwaite's method ['lmerModLmerTest']
## Formula: Score ~ Time_num + (Time_num | subject)
##    Data: long
##
## REML criterion at convergence: 2850.7
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -2.66966 -0.58568 -0.02789  0.62411  2.54319
##
## Random effects:
##  Groups   Name        Variance Std.Dev. Corr
##  subject  (Intercept)  5.464   2.337
##           Time_num     1.026   1.013    0.45
##  Residual             14.835   3.852
## Number of obs: 480, groups:  subject, 80
##
## Fixed effects:
##             Estimate Std. Error      df t value Pr(>|t|)
## (Intercept)  37.8982     0.4067 79.0017   93.18   <2e-16 ***
## Time_num     -2.4093     0.1530 78.9998  -15.74   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
##          (Intr)
## Time_num -0.210
```

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Latente Wachstumskurvenmodelle

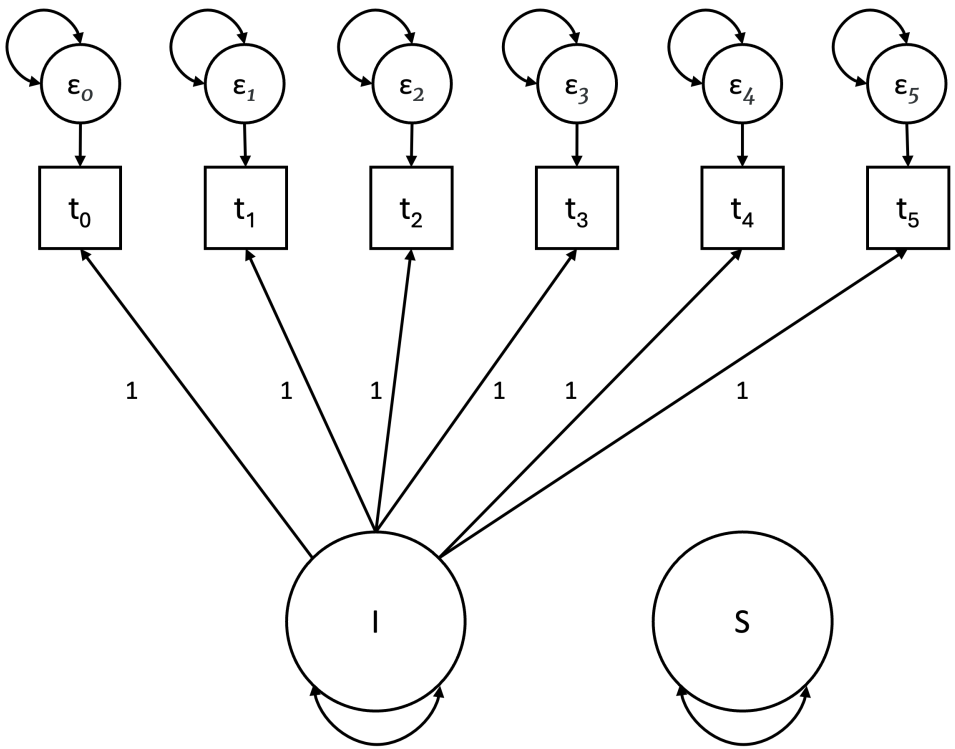


- Im latenten Wachstumskurvenmodell sind messwiederholte Werte manifeste Indikatoren
- Veränderung (Slope) und Ausgangsniveau (Intercept) werden als latente Variablen modelliert
- Beide haben eine Varianz (random Intercept und random Slope)
- Der Schlüssel für die Modellierung der Messwiederholung liegt in der besonderen Fixierung der Pfade

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

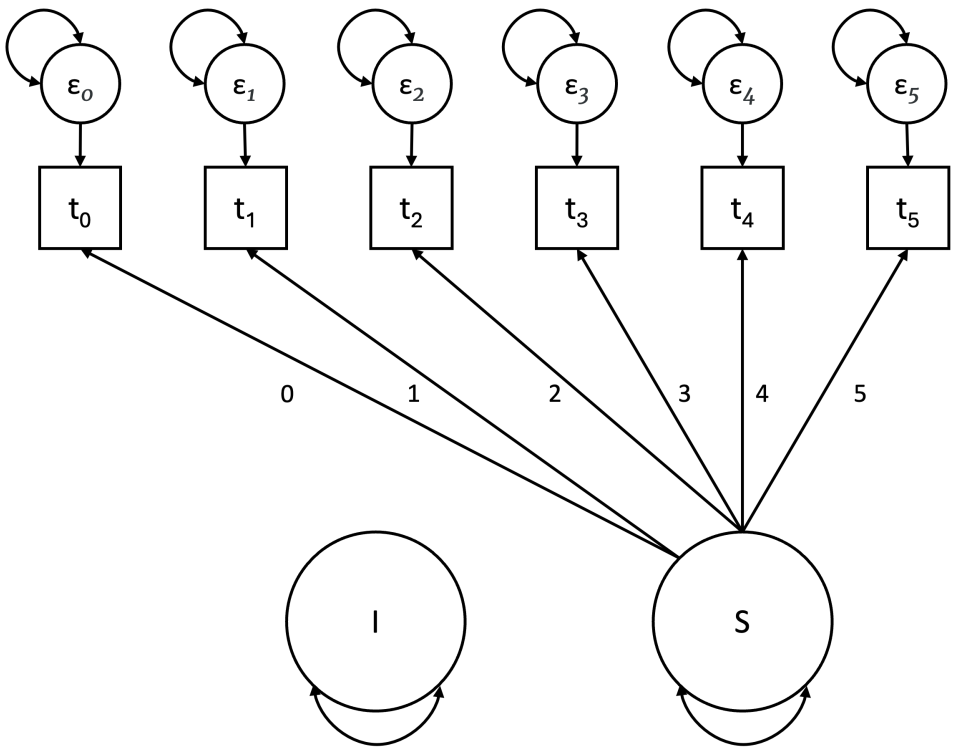
Latente Wachstumskurvenmodelle



- Der Schlüssel für die Modellierung der Messwiederholung liegt in der besonderen Fixierung der Pfade
- Für den Intercept werden alle Ladungen auf 1 fixiert

Multivariate (latente) Modellierung

Latente Wachstumskurvenmodelle



- Der Schlüssel für die Modellierung der Messwiederholung liegt in der besonderen Fixierung der Pfade
- Für den Slope werden die Ladungen kontinuierlich durchnummeriert (beginnend mit 0 = Baseline)
- Dies entspricht einem linearen Wachstumsfaktor
- Sollen andere Abstände modelliert werden, können die Zahlen angepasst werden (z.B. in tatsächlichen Wochenabständen)

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Latente Wachstumskurvenmodelle

Beispiel: Latente Wachstumskurvenmodelle: Therapieansprechen

Latente Wachstumskurvenmodelle in `lavaan`:

```
model <- '

i =~ 1*t0 + 1*t1 + 1*t2 + 1*t3 + 1*t4 + 1*t5

s =~ 0*t0 + 1*t1 + 2*t2 + 3*t3 + 4*t4 + 5*t5
'

fit <- growth(model, data = df)
```

subject	t0	t1	t2	t3	t4	t5
21a	43	39	30	32	32	21
22a	35	35	24	17	21	24
23a	40	37	31	24	31	21
24a	36	36	32	25	33	26
25a	35	32	24	20	27	27
26a	39	34	32	27	34	21
27a	32	26	24	22	13	8
28a	40	41	26	30	24	22
29a	39	34	32	17	22	11
30a	38	42	27	19	12	19
31a	39	33	33	29	22	24
32a	36	36	28	27	27	17
33a	37	41	24	33	34	30
34a	34	29	30	23	19	24
35a	36	35	29	19	22	19

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Latente Wachstumskurvenmodelle

```
summary(lmm_model) # lme4
```

```
Scaled residuals:
     Min       1Q   Median       3Q      Max
-2.66966 -0.58568 -0.02789  0.62411  2.54319

Random effects:
 Groups   Name        Variance Std.Dev. Corr
 subject  (Intercept)  5.464   2.337
          Time_num     1.026   1.013    0.45
 Residual             14.835   3.852
Number of obs: 480, groups:  subject, 80

Fixed effects:
            Estimate Std. Error      df t value Pr(>|t|)
(Intercept)  37.8982     0.4067 79.0017   93.18   <2e-16 ***
Time_num     -2.4093     0.1530 78.9998  -15.74   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Correlation of Fixed Effects:
         (Intr)
Time_num -0.210
```

```
summary(fit) # lavaan (Messmodell)
```

```
Latent Variables:
                   Estimate  Std.Err  z-value  P(>|z|)
  i =~
    t0                1.000
    t1                1.000
    t2                1.000
    t3                1.000
    t4                1.000
    t5                1.000
  s =~
    t0                0.000
    t1                1.000
    t2                2.000
    t3                3.000
    t4                4.000
    t5                5.000
```

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Latente Wachstumskurvenmodelle

```
summary(lmm_model) # lme4
```

```
Scaled residuals:
     Min       1Q   Median       3Q      Max
-2.66966 -0.58568 -0.02789  0.62411  2.54319

Random effects:
 Groups   Name        Variance Std.Dev. Corr
 subject  (Intercept)  5.464   2.337
          Time_num     1.026   1.013    0.45
 Residual             14.835   3.852
Number of obs: 480, groups:  subject, 80

Fixed effects:
            Estimate Std. Error      df t value Pr(>|t|)
(Intercept)  37.8982     0.4067 79.0017   93.18   <2e-16 ***
Time_num     -2.4093     0.1530 78.9998  -15.74   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Correlation of Fixed Effects:
         (Intr)
Time_num -0.210
```

```
summary(fit) # lavaan (Strukturmodell)
```

```
Covariances:
                   Estimate  Std.Err  z-value  P(>|z|)
  i ~~
    s                 0.236    0.597    0.396    0.692

Intercepts:
                   Estimate  Std.Err  z-value  P(>|z|)
    i                37.604    0.377   99.829    0.000
    s                -2.320    0.155  -14.987    0.000

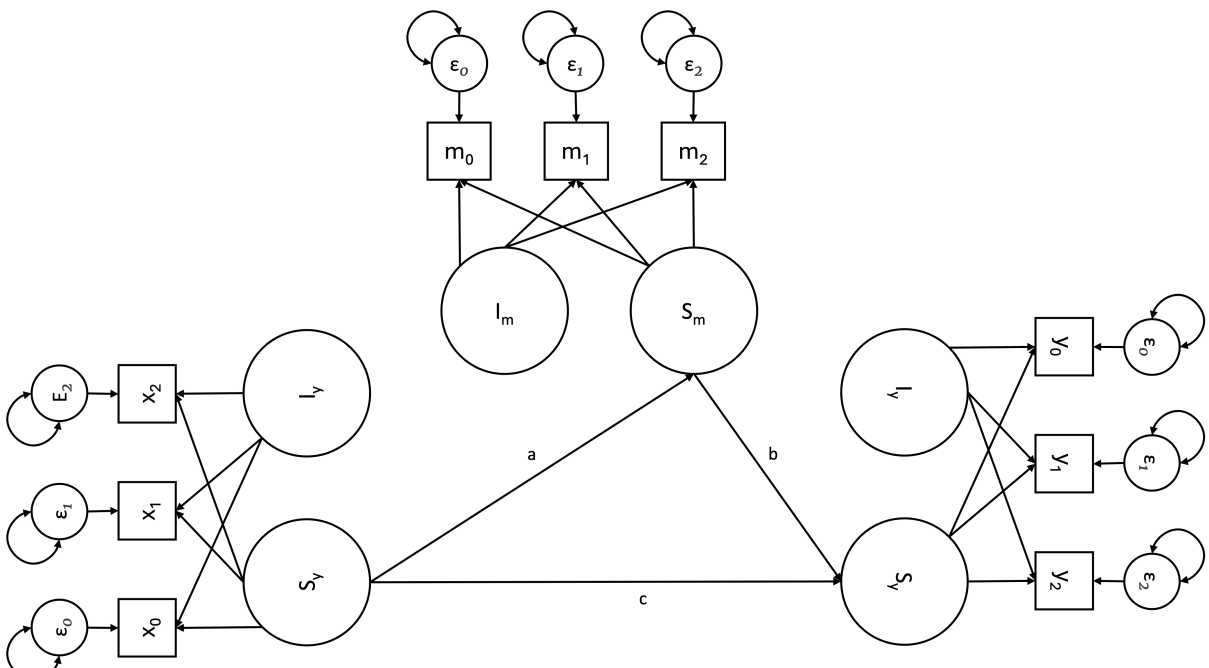
Variances:
                   Estimate  Std.Err  z-value  P(>|z|)
   .t0                6.618    1.929    3.431    0.001
   .t1               13.116    2.391    5.485    0.000
   .t2               15.454    2.752    5.615    0.000
   .t3               20.708    3.719    5.569    0.000
   .t4               15.434    3.316    4.654    0.000
   .t5               15.083    4.105    3.674    0.000
    i                 6.715    2.035    3.299    0.001
    s                 1.286    0.319    4.037    0.000
```

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Latente Wachstumskurvenmodelle

Latente Wachstumskurvenmodelle ermöglichen komplexe Analysen (z.B. Mediation latenter Variablen)



Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Messinvarianzprüfung

- Messinvarianz = ein Messinstrument funktioniert über verschiedene Gruppen (z. B. Geschlecht, Altersgruppen, Kulturen) oder über die Zeit hinweg gleich
- Messinvarianzprüfung - Ziel:
  - Sicherstellen, dass Unterschiede in den gemessenen Werten echte Unterschiede in der zugrunde liegenden latenten Variable darstellen
  - Unterschiede sind nicht lediglich durch Unterschiede in der Messweise bedingt.
- Praktische Relevanz:
  - Ermöglicht faire Gruppenvergleiche.
  - Prüft, ob das Konstrukt (z. B. Intelligenz, Angst) in allen Gruppen gleich interpretiert wird.
  - Sicherstellung, dass Veränderungen über die Zeit tatsächlich auf eine Veränderung des Konstrukts zurückzuführen sind.

Messinvarianzprüfung

Wenn die Daten kontinuierlich sind, umfasst die Prüfung der Messinvarianz eine festgelegte Abfolge von Modellvergleichstests:

1. Konfigurale Invarianz (engl. configural invariance)

- Die gleiche **Faktorstruktur** wird in allen Gruppen angenommen, ohne dass weitere Einschränkungen vorgenommen werden.

2. Schwache Invarianz (engl. metric invariance)

- Die **Faktorladungen** werden zwischen den Gruppen gleichgesetzt
- d. h., die Beziehungen zwischen den Indikatoren und den latenten Variablen sind in allen Gruppen gleich

3. Starke Invarianz (engl. scalar invariance)

- Sowohl die **Faktorladungen** als auch die **Intercepts** werden zwischen den Gruppen gleichgesetzt
- d. h., dass die gemessenen Variablen in allen Gruppen die latenten Variablen gleich repräsentieren.

4. Strenge Invarianz (engl. strict invariance)

- Setzt Gleichheit der einzigartigen Varianzen oder der Residualvarianzen voraus
- In der Praxis wird jedoch das Erreichen der ersten drei Invarianzstufen als ausreichend angesehen (Van de Schoot et al., 2012)

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Messinvarianzprüfung

- Gängige Methode: Multi-Group Confirmatory Factor Analysis (MGCFA)
- Nutzbare Funktionen für MGCFA in `lavaan`:
  - `anova()`
  - `compareFit()`
  - `lavTestLRT()`
- Modelle werden simultan für alle Gruppen innerhalb eines Gesamtmodells angepasst.
- Für unterschiedliche strenge Invarianzstufen, werden zusätzliche Parameter fixiert (engl. contraints)
- Sollen ganze Gruppen von Parametern (z.B. alle Ladungen) zwischen Gruppen gleichgehalten werden, geht dies mit der Funktion `group.equal`
  - Vorteil: Nicht alle Parameter müssen händisch im Modell angepasst werden

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Messinvarianzprüfung

Beispiel: dunkle Triade der Persönlichkeit

- 3 Faktoren (jeweils 3 Items):
  - Narzissmus
  - Machiavellismus
  - subklinische Psychopathie
- Struktur des Fragebogens wurde mittels CFA geprüft
- Frage: Ist Fragebogen messinvariant für Frauen und Männer?

Geschlecht	Item1	Item2	Item3	Item4	Item5	Item6	Item7	Item8	Item9
weiblich	3	8	0	2	6	1	3	6	6
weiblich	5	5	2	2	3	1	4	6	8
weiblich	5	6	3	2	3	1	4	5	5
weiblich	6	8	4	3	5	3	4	6	5
weiblich	6	6	2	3	5	3	4	7	7
weiblich	5	5	2	1	3	1	4	7	8
weiblich	2	5	0	3	5	2	4	5	4
weiblich	6	7	2	4	5	2	4	6	4
weiblich	5	6	2	3	6	3	5	5	8
weiblich	3	5	0	2	5	2	4	4	4
weiblich	3	5	2	2	3	1	3	5	4
weiblich	7	7	4	4	6	4	5	6	5
weiblich	7	6	5	4	5	4	7	7	7
weiblich	6	6	2	5	4	2	5	5	5
weiblich	5	5	3	5	5	3	4	4	5

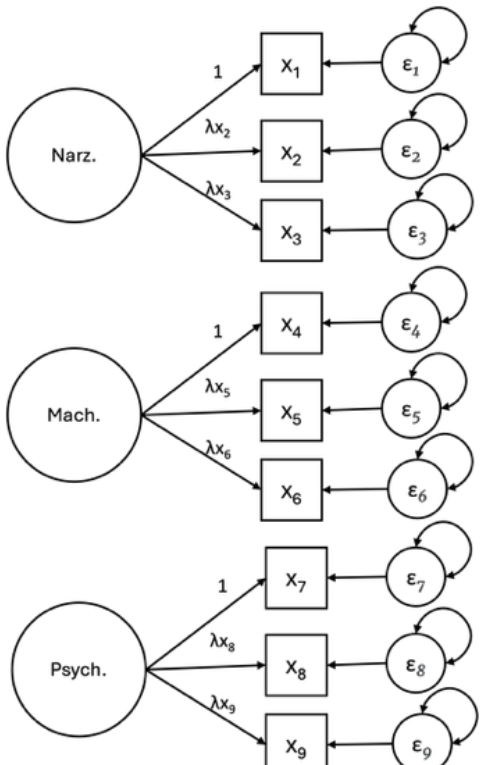
Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Messinvarianzprüfung

Beispiel: dunkle Triade der Persönlichkeit

- 3 Faktoren (jeweils 3 Items):
  - Narzissmus
  - Machiavellismus
  - subklinische Psychopathie
- Struktur des Fragebogens wurde mittels CFA geprüft
- Frage: Ist Fragebogen messinvariant für Frauen und Männer?



Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Messinvarianzprüfung

- Zunächst formulieren wir das Mesmodell für die Dunkle Triade der Persönlichkeit
- Dann werden Modelle mit allen Stufen von Parameterfixierungen zwischen den Geschlechtern aufgestellt

```
dark.model <- ' Narzissmus  =~ Item1 + Item2 + Item3
                Machiavellismus =~ Item4 + Item5 + Item6
                Psychotizismus   =~ Item7 + Item8 + Item9'

# Konfigurale Invarianz

fit1 <- cfa(dark.model, data = df, group = "Geschlecht")

# Metrische Invarianz

fit2 <- cfa(dark.model, data = df, group = "Geschlecht", group.equal = "loadings")

# Skalar Invarianz

fit3 <- cfa(dark.model, data = df, group = "Geschlecht", group.equal = c("intercepts", "loadings"))
```

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Messinvarianzprüfung

```
# Messinvarianzprüfung (Modellvergleich)

lavTestLRT(fit1, fit2, fit3)
```

```
##
## Chi-Squared Difference Test
##
##      Df    AIC    BIC   Chisq Chisq diff    RMSEA Df diff Pr(>Chisq)
## fit1 48 8182.0 8404.5  99.808
## fit2 54 8180.1 8380.3 109.922     10.113 0.067493       6       0.12
## fit3 60 8204.9 8382.8 146.683     36.761 0.184569       6   1.96e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- Wir haben 3 Modellanpassungen angegeben → es werden zwei Tests durchgeführt:
  - Der 1. Test vergleicht das erste Modell mit dem zweiten Modell
  - Der 2. Test vergleicht das zweite Modell mit dem dritten Modell

Multivariate (latente) Modellierung

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

Messinvarianzprüfung

```
# Messinvarianzprüfung (Modellvergleich)

lavTestLRT(fit1, fit2, fit3)
```

```
##
## Chi-Squared Difference Test
##
##      Df    AIC    BIC   Chisq Chisq diff    RMSEA Df diff Pr(>Chisq)
## fit1 48 8182.0 8404.5  99.808
## fit2 54 8180.1 8380.3 109.922     10.113 0.067493       6       0.12
## fit3 60 8204.9 8382.8 146.683     36.761 0.184569       6   1.96e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- Erster p-Wert nicht signifikant $\rightarrow$ die schwache Invarianz (gleiche Faktorladungen) wird in diesem Datensatz unterstützt
- Zweiter p-Wert signifikant $\rightarrow$ die starke Invarianz wird in diesem Datensatz nicht unterstützt

Take-aways

CHARLOTTE FRESENIUS HOCHSCHULE
UNIVERSITY OF PSYCHOLOGY

- Mediation ermöglicht Untersuchung indirekter Effekte: Vermittlung zwischen UV und AV.
- Bootstrapping als robuste Methode zur Schätzung von indirekten Effekten.
- Latente Wachstumskurvenmodelle ermöglichen Analyse von Entwicklungsverläufen über die Zeit.
- Vorteil latenter Wachstumskurvenmodelle: Berücksichtigung von Messfehlern und Analyse mehrerer messwiederholter Variablen im selben Modell
- Messinvarianzprüfung stellt sicher, dass Messinstrumente über Gruppen/Zeiträume hinweg gleich funktionieren.
- Drei zentrale Stufen der Messinvarianzprüfung: Konfigurale, schwache und starke Invarianz.
- Messinvarianz ist Voraussetzung für valide Gruppenvergleiche und Interpretation latenter Mittelwerte.